

Математический и концептуальный базис генеративной диффузии: от Score Matching к NCSN

Автор исследования: Че Алина

Аннотация

В работе проводится анализ эволюции диффузионных и score-based моделей (2005–2019). В обзоре подробно разбираются проблемы, связанные с ненормированными статистическими моделями, вычислительные барьеры вычисления высших производных, термодинамические основы марковских процессов и топологические ограничения гипотезы многообразий.

1 Hyvärinen (2005) — Estimation of Non-Normalized Statistical Models by Score Matching

1.1 Постановка задачи

Пусть наблюдается случайный вектор $\mathbf{x} \in \mathbb{R}^n$ с неизвестной плотностью $p_{\mathbf{x}}(\cdot)$. Задана параметрическая модель плотности:

$$p(\boldsymbol{\xi}; \boldsymbol{\theta}) = \frac{1}{Z(\boldsymbol{\theta})} q(\boldsymbol{\xi}; \boldsymbol{\theta}), \quad Z(\boldsymbol{\theta}) = \int_{\mathbb{R}^n} q(\boldsymbol{\xi}; \boldsymbol{\theta}) d\boldsymbol{\xi},$$

где $q(\cdot)$ известна аналитически, а $Z(\boldsymbol{\theta})$ неизвестна и трудно вычислима в многомерном случае ($n > 2$). Цель — оценить $\boldsymbol{\theta}$ по выборке $\mathbf{x}(1), \dots, \mathbf{x}(T)$ без вычисления $Z(\boldsymbol{\theta})$.

1.2 Основная идея: согласование скоры (Score Matching)

Определим **score-функцию** модели как градиент логарифма плотности:

$$\boldsymbol{\psi}(\boldsymbol{\xi}; \boldsymbol{\theta}) = \nabla_{\boldsymbol{\xi}} \log p(\boldsymbol{\xi}; \boldsymbol{\theta}) = \nabla_{\boldsymbol{\xi}} \log q(\boldsymbol{\xi}; \boldsymbol{\theta}).$$

Важно: $\boldsymbol{\psi}$ не зависит от $Z(\boldsymbol{\theta})$.

Аналогично, score-функция данных: $\boldsymbol{\psi}_{\mathbf{x}}(\boldsymbol{\xi}) = \nabla_{\boldsymbol{\xi}} \log p_{\mathbf{x}}(\boldsymbol{\xi})$.

Предлагается минимизировать ожидаемое квадратичное расстояние между ними:

$$J(\boldsymbol{\theta}) = \frac{1}{2} \int_{\mathbb{R}^n} p_{\mathbf{x}}(\boldsymbol{\xi}) \|\boldsymbol{\psi}(\boldsymbol{\xi}; \boldsymbol{\theta}) - \boldsymbol{\psi}_{\mathbf{x}}(\boldsymbol{\xi})\|^2 d\boldsymbol{\xi}.$$

1.3 Главная теорема (Theorem 1)

Теорема 1.1. При условиях гладкости (дифференцируемость $\boldsymbol{\psi}$ и граничные условия) функционал $J(\boldsymbol{\theta})$ может быть выражен как

$$J(\boldsymbol{\theta}) = \int_{\mathbb{R}^n} p_{\mathbf{x}}(\boldsymbol{\xi}) \sum_{i=1}^n \left[\partial_i \psi_i(\boldsymbol{\xi}; \boldsymbol{\theta}) + \frac{1}{2} \psi_i(\boldsymbol{\xi}; \boldsymbol{\theta})^2 \right] d\boldsymbol{\xi} + \text{const},$$

где

$$\psi_i = \frac{\partial \log q}{\partial \xi_i}, \quad \partial_i \psi_i = \frac{\partial^2 \log q}{\partial \xi_i^2}.$$

Ключевое следствие: $J(\theta)$ выражается только через q и не требует знания $\psi_{\mathbf{x}}$ или $p_{\mathbf{x}}$. На практике используется выборочная оценка:

$$\tilde{J}(\theta) = \frac{1}{T} \sum_{t=1}^T \sum_{i=1}^n \left[\partial_i \psi_i(\mathbf{x}(t); \theta) + \frac{1}{2} \psi_i(\mathbf{x}(t); \theta)^2 \right] + \text{const.}$$

1.4 Состоятельность оценки

Теорема 1.2. Если данные порождены моделью с параметром θ^* , $q > 0$ и модель не вырождена, то

$$J(\theta) = 0 \quad \Leftrightarrow \quad \theta = \theta^*.$$

Теорема 1.3. При $T \rightarrow \infty$ оценка $\hat{\theta} = \arg \min \tilde{J}(\theta)$ сходится по вероятности к θ^* (глобальная состоятельность при нахождении глобального минимума; локальная — в противном случае).

1.5 Ограничения метода

- Только для непрерывных переменных $\mathbf{x} \in \mathbb{R}^n$.
- Требуется гладкость плотности (дифференцируемость).
- Не применим напрямую к дискретным или латентным переменным.
- Локальная состоятельность требует хорошего начального приближения.

1.6 Выводы

1. Score Matching — простой, детерминированный и состоятельный метод для оценки ненормированных моделей.
2. Первый член в J (вторая производная) играет роль нормировки, противодействуя неограниченному росту ненормированного правдоподобия.
3. Метод лёг в основу многих современных подходов.

2 Vincent (2010) — A Connection Between Score Matching and Denoising Autoencoders

2.1 Введение

Score matching (Hyvarinen, 2005) — мощный метод обучения ненормированных моделей плотности, но он требует вычисления вторых производных (гессиана) и может быть нестабильным на конечных выборках.

2.2 Обозначения и предварительные сведения

Определение 2.1 (Эмпирическая плотность).

$$q_0(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \delta(\|\mathbf{x} - \mathbf{x}^{(i)}\|),$$

где δ — дельта-функция Дирака.

Определение 2.2 (Гауссовское ядро (шумовая модель)).

$$q_\sigma(\tilde{\mathbf{x}}|\mathbf{x}) = \frac{1}{(2\pi)^{d/2}\sigma^d} \exp\left(-\frac{1}{2\sigma^2}\|\tilde{\mathbf{x}} - \mathbf{x}\|^2\right).$$

Здесь σ — уровень шума.

Определение 2.3 (Оценка Парзена).

$$q_\sigma(\tilde{\mathbf{x}}) = \int q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})q_0(\mathbf{x})d\mathbf{x} = \frac{1}{n} \sum_{t=1}^n q_\sigma(\tilde{\mathbf{x}}|\mathbf{x}^{(t)}).$$

2.3 Denoising Autoencoder (DAE)

Рассмотрим DAE с одним скрытым слоем, линейным декодером, квадратичной ошибкой и связанными весами ($\mathbf{W}$ для энкодера и $\mathbf{W}^T$ для декодера).

Определение 2.4 (Процедура DAE). 1. Исходный образец $\mathbf{x} \sim q_0$ зашумляется: $\tilde{\mathbf{x}} = \mathbf{x} + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$.

2. Кодирование: $\mathbf{h} = \text{sigmoid}(\mathbf{W}\tilde{\mathbf{x}} + \mathbf{b})$.

3. Декодирование: $\mathbf{x}^r = \mathbf{W}^T \mathbf{h} + \mathbf{c}$.

4. Цель: минимизировать $\mathbb{E}[\|\mathbf{x}^r - \mathbf{x}\|^2]$.

Формально целевая функция DAE:

$$J_{DAE_\sigma}(\theta) = \mathbb{E}_{q_\sigma(\tilde{\mathbf{x}}, \mathbf{x})} [\|\mathbf{W}^T \text{sigmoid}(\mathbf{W}\tilde{\mathbf{x}} + \mathbf{b}) + \mathbf{c} - \mathbf{x}\|^2],$$

где $\theta = \{\mathbf{W}, \mathbf{b}, \mathbf{c}\}$.

2.4 Score Matching: напоминание

2.4.1 Explicit Score Matching (ESM)

$$J_{ESM_q}(\theta) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \left\| \psi(\mathbf{x}; \theta) - \frac{\partial \log q(\mathbf{x})}{\partial \mathbf{x}} \right\|^2 \right],$$

где $\psi(\mathbf{x}; \theta) = \frac{\partial \log p(\mathbf{x}; \theta)}{\partial \mathbf{x}}$ — score модели.

2.4.2 Implicit Score Matching (ISM)

В предыдущей статье доказано (при условиях регулярности):

$$J_{ESM_q}(\theta) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\psi(\mathbf{x}; \theta)\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(\mathbf{x}; \theta)}{\partial x_i} \right] + \text{const.}$$

$$J_{ISM_q}(\theta) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\psi(\mathbf{x}^{(t)}; \theta)\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(\mathbf{x}^{(t)}; \theta)}{\partial x_i} \right]$$

Выборочная:

$$J_{ISM_{q_0}}(\theta) = \frac{1}{n} \sum_{t=1}^n \left(\frac{1}{2} \|\psi(\mathbf{x}^{(t)}; \theta)\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(\mathbf{x}^{(t)}; \theta)}{\partial x_i} \right).$$

2.5 Основной результат: связь между SM и DAE

2.5.1 Шаг 1: Score Matching для оценки Парзена

q_σ :

$$J_{ESM_{q_\sigma}}(\theta) = \mathbb{E}_{q_\sigma(\tilde{\mathbf{x}})} \left[\frac{1}{2} \left\| \psi(\tilde{\mathbf{x}}; \theta) - \frac{\partial \log q_\sigma(\tilde{\mathbf{x}})}{\partial \tilde{\mathbf{x}}} \right\|^2 \right].$$

$$J_{ESM_{q_\sigma}}(\theta) \sim J_{ISM_{q_\sigma}}(\theta),$$

2.5.2 Шаг 2: Denoising Score Matching (DSM)

$$J_{DSM_{q_\sigma}}(\theta) = \mathbb{E}_{q_\sigma(\mathbf{x}, \tilde{\mathbf{x}})} \left[\frac{1}{2} \left\| \psi(\tilde{\mathbf{x}}; \theta) - \frac{\partial \log q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})}{\partial \tilde{\mathbf{x}}} \right\|^2 \right].$$

Предложение 2.1 (Эквивалентность ESM и DSM). Для любого $\sigma > 0$ (при условиях регулярности) выполнено:

$$J_{ESM_{q_\sigma}}(\theta) \sim J_{DSM_{q_\sigma}}(\theta),$$

т.е. эти критерии совпадают с точностью до аддитивной константы, не зависящей от θ .

2.5.3 Шаг 3: Выбор энергетической функции модели

$$E(\mathbf{x}; \mathbf{W}, \mathbf{b}, \mathbf{c}) = - \frac{\langle \mathbf{c}, \mathbf{x} \rangle - \frac{1}{2} \|\mathbf{x}\|^2 + \sum_{j=1}^{d_h} \text{softplus}(\langle \mathbf{W}_j, \mathbf{x} \rangle + b_j)}{\sigma^2},$$

где $\text{softplus}(u) = \log(1 + e^u)$.

Предложение 2.2 (Score).

$$\psi(\mathbf{x}; \theta) = \frac{\partial \log p(\mathbf{x}; \theta)}{\partial \mathbf{x}} = \frac{1}{\sigma^2} (\mathbf{W}^T \text{sigmoid}(\mathbf{W}\mathbf{x} + \mathbf{b}) + \mathbf{c} - \mathbf{x}).$$

2.5.4 Шаг 4: Эквивалентность DSM и DAE

Подставляя выражения для ψ и $\frac{\partial \log q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})}{\partial \tilde{\mathbf{x}}} = \frac{1}{\sigma^2}(\mathbf{x} - \tilde{\mathbf{x}})$ в $J_{DSM_{q_\sigma}}$, получаем:

$$J_{DSM_{q_\sigma}}(\theta) = \frac{1}{2\sigma^4} \mathbb{E}_{q_\sigma(\mathbf{x}, \tilde{\mathbf{x}})} [\|\mathbf{W}^T \text{sigmoid}(\mathbf{W}\tilde{\mathbf{x}} + \mathbf{b}) + \mathbf{c} - \mathbf{x}\|^2] = \frac{1}{2\sigma^4} J_{DAE_\sigma}(\theta).$$

Таким образом, минимизация J_{DAE_σ} эквивалентна минимизации $J_{DSM_{q_\sigma}}$.

2.5.5 Итоговая цепочка эквивалентностей

Для $\sigma > 0$:

$$J_{ISM_{q_\sigma}} \sim J_{ESM_{q_\sigma}} \sim J_{DSM_{q_\sigma}} \sim J_{DAE_\sigma}$$

2.6 Итоги

2.6.1 Для Score Matching

1. Установлена связь между Score Matching и Denoising Autoencoders.
2. DAE получил строгое вероятностное обоснование как метод обучения энергетической модели.
3. Преимущества DSM:

$$J_{DSM}(\theta) = \mathbb{E}_{\mathbf{x} \sim q_0, \tilde{\mathbf{x}} \sim \mathcal{N}(\mathbf{x}, \sigma^2 I)} \left[\frac{1}{2} \left\| \psi(\tilde{\mathbf{x}}; \theta) - \frac{\mathbf{x} - \tilde{\mathbf{x}}}{\sigma^2} \right\|^2 \right].$$

- Не требует вторых производных (в отличие от ISM).
- Естественная регуляризация за счет шума (σ контролирует смещение-дисперсию).
- Легко реализуется через стохастический градиентный спуск.

3 Song & Ermon (2019) — Generative Modeling by Estimating Gradients of the Data Distribution (NCSN)

3.1 Введение

3.1.1 Основная идея: score-based generative modeling

Вместо оценки плотности $p_{\text{data}}(\mathbf{x})$ напрямую, предлагается оценивать score:

$$\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}),$$

а затем семплировать с помощью динамики Ланжевена.

Определение 3.1. Score — это градиент логарифма плотности. Для распределения $p(\mathbf{x})$:

$$\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p(\mathbf{x}) \in \mathbb{R}^D.$$

3.2 Основы score-based генеративного моделирования

3.2.1 Score matching для оценки score

Score matching (Hyvarinen, 2005) позволяет обучать сеть $\mathbf{s}_{\theta}(\mathbf{x})$ приближать $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ без знания самой плотности.

Теорема 3.1 (Score Matching Objective).

$$J(\theta) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|^2] = \mathbb{E}_{p_{\text{data}}} \left[(\nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_{\theta}(\mathbf{x})\|^2 \right] + \text{const.}$$

3.2.2 Масштабируемые варианты score matching

Denoising Score Matching (Vincent, 2011): Для зашумленных данных с $q_\sigma(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}|\mathbf{x}, \sigma^2 I)$:

$$\ell(\theta; \sigma) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\tilde{\mathbf{x}} \sim \mathcal{N}(\mathbf{x}, \sigma^2 I)} \left[\left\| \mathbf{s}_\theta(\tilde{\mathbf{x}}) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2} \right\|^2 \right].$$

Sliced Score Matching (Song et al., 2019): Использует случайные проекции для обхода вычисления следа Якобиана:

$$J_{\text{SSM}}(\theta) = \mathbb{E}_{p_{\text{data}}} \mathbb{E}_{\mathbf{v} \sim \mathcal{N}(0, I)} \left[\mathbf{v}^\top \nabla_{\mathbf{x}} \mathbf{s}_\theta(\mathbf{x}) \mathbf{v} + \frac{1}{2} \|\mathbf{s}_\theta(\mathbf{x})\|^2 \right].$$

3.2.3 Семплирование с помощью динамики Ланжевена

Для выборки из распределения $p(\mathbf{x})$ используется итеративный процесс:

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_{t-1} + \frac{\epsilon}{2} \nabla_{\mathbf{x}} \log p(\tilde{\mathbf{x}}_{t-1}) + \sqrt{\epsilon} \mathbf{z}_t, \quad \mathbf{z}_t \sim \mathcal{N}(0, I).$$

При $\epsilon \rightarrow 0$ и $T \rightarrow \infty$ распределение $\tilde{\mathbf{x}}_T$ стремится к $p(\mathbf{x})$.

3.3 Проблемы score-based генеративного моделирования

Проблема 3.2. *Реальные данные концентрируются на низкоразмерных многообразиях в пространстве большей размерности.*

Тогда:

- Score $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ не определен на многообразии.
- Score matching дает несостоятельную оценку.

Экспериментальное подтверждение: Обучение на CIFAR-10 без шума приводит к нестабильной loss-функции. Добавление малого шума $\mathcal{N}(0, 0.0001)$ стабилизирует обучение.

Проблема 3.3. *В областях, где $p_{\text{data}}(\mathbf{x}) \approx 0$, нет обучающих примеров, поэтому score оценивается неточно.*

Тогда:

- Неточная оценка score: вдали от мод распределения ошибка велика.
- Медленное смешивание: динамика Ланжевена не может правильно восстановить веса между разными модами, если они разделены областями низкой плотности.

Пример: Для смеси двух гауссиан $p_{\text{data}} = \frac{1}{5} \mathcal{N}((-5, -5), I) + \frac{4}{5} \mathcal{N}((5, 5), I)$ динамика Ланжевена с точным score дает неверное соотношение весов.

3.4 Метод: Noise Conditional Score Networks (NCSN)

3.4.1 Ключевая идея

1. Возмущаем данные гауссовским шумом различных уровней $\{\sigma_i\}_{i=1}^L$.
2. Обучаем одну условную сеть $\mathbf{s}_\theta(\mathbf{x}, \sigma)$ оценивать score для всех уровней шума:

$$\mathbf{s}_\theta(\mathbf{x}, \sigma_i) \approx \nabla_{\mathbf{x}} \log q_{\sigma_i}(\mathbf{x}), \quad q_{\sigma_i}(\mathbf{x}) = \int p_{\text{data}}(\mathbf{t}) \mathcal{N}(\mathbf{x}|\mathbf{t}, \sigma_i^2 I) d\mathbf{t}.$$

3. Для семплирования используем Annealed Langevin dynamics: начинаем с большого σ_1 (где распределение гладкое и хорошо перемешивается) и постепенно уменьшаем σ до $\sigma_L \approx 0$.

3.4.2 Выбор уровней шума

Уровни шума образуют геометрическую прогрессию:

$$\sigma_1 > \sigma_2 > \dots > \sigma_L, \quad \frac{\sigma_1}{\sigma_2} = \dots = \frac{\sigma_{L-1}}{\sigma_L} > 1.$$

В экспериментах: $L = 10$, $\sigma_1 = 1$, $\sigma_L = 0.01$ (для изображений).

3.4.3 Целевая функция NCSN

Объединяем denoising score matching для всех σ_i :

$$\mathcal{L}(\theta; \{\sigma_i\}_{i=1}^L) = \frac{1}{L} \sum_{i=1}^L \lambda(\sigma_i) \ell(\theta; \sigma_i),$$

где

$$\ell(\theta; \sigma) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}} \mathbb{E}_{\tilde{\mathbf{x}} \sim \mathcal{N}(\mathbf{x}, \sigma^2 I)} \left[\left\| \mathbf{s}_\theta(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2} \right\|^2 \right].$$

Замечание 3.1 (Выбор $\lambda(\sigma)$). Выбираем $\lambda(\sigma) = \sigma^2$, чтобы все слагаемые в сумме имели одинаковый масштаб:

$$\lambda(\sigma) \ell(\theta; \sigma) = \frac{1}{2} \mathbb{E} \left[\left\| \sigma \mathbf{s}_\theta(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma} \right\|^2 \right].$$

3.4.4 Annealed Langevin Dynamics

1. Инициализируем $\tilde{\mathbf{x}}_0 \sim \mathcal{U}(-1, 1)$.
2. $i = 1 \rightarrow L$:
 - (a) $\alpha_i \leftarrow \epsilon \cdot \sigma_i^2 / \sigma_L^2$
 - (b) $t = 1 \rightarrow T$:
 - i. $\mathbf{z}_t \sim \mathcal{N}(0, \mathbf{I})$
 - ii. $\tilde{\mathbf{x}}_t \leftarrow \tilde{\mathbf{x}}_{t-1} + \frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t$
 - (c) $\tilde{\mathbf{x}}_0 \leftarrow \tilde{\mathbf{x}}_T$

3. return $\tilde{\mathbf{x}}_T$

Замечание 3.2 (Почему это работает?). • При большом σ_1 распределение q_{σ_1} размывается, моды менее изолированы — смешивание быстрое.

- Семплы из $q_{\sigma_{i-1}}$ служат хорошей инициализацией для q_{σ_i} .
- Постепенное уменьшение шума позволяет "переносить" информацию из областей высокой плотности.

3.5 Преимущества и ограничения

3.5.1 Преимущества

1. Нет adversarial-обучения — обучение стабильно.
2. Гибкость архитектур — не требуется специальных ограничений.
3. Принципиальная метрика — objective позволяет сравнивать модели.
4. Естественный инпейнтинг — через модификацию семплирования.

3.5.2 Ограничения

1. Медленное семплирование — требуется $L \times T$ шагов (в статье $L = 10, T = 100$).
2. Требуется выбора гиперпараметров ($\{\sigma_i\}, \epsilon, T$).
3. Только для непрерывных данных (непосредственно).

Заключение

В работе проведен анализ ключевых этапов развития диффузионных и score-based моделей в период 2005–2019 гг. Показано, что Score Matching (Hyvärinen, 2005) решило проблему обучения ненормированных моделей, с помощью Denoising Score Matching (Vincent, 2010) устранились вычислительные сложности, связанные со вторыми производными, а благодаря NCSN (Song & Ermon, 2019) решилась проблема топологических ограничений гипотезы многообразий через добавление разных уровней шума. Рассмотренные методы составляют теоретический фундамент современных диффузионных моделей.

Список литературы

- [1] Hyvärinen, A. (2005). *Estimation of Non-Normalized Statistical Models by Score Matching*. Journal of Machine Learning Research.
- [2] Vincent, P. (2010). *A Connection Between Score Matching and Denoising Autoencoders*. Neural Computation.
- [3] Song, Y., & Ermon, S. (2019). *Generative Modeling by Estimating Gradients of the Data Distribution*. Advances in Neural Information Processing Systems (NeurIPS).